


Projektstand

Phase 0 ist abgeschlossen. Die Lern- und Sample-Pipelines wurden entfernt; das Repository bildet jetzt ausschließlich den realen OpenAQ-Kafka-Spark-Pfad ab.



Git-Stand: dev und origin/dev auf Commit 9009fd5 - Working Tree sauber

Laufende Datenstrecke



Der Producer ruft aktuelle OpenAQ-Messungen ab, reichert sie mit Sensormetadaten an und veröffentlicht kanonische Events. Spark liest die Events checkpoint-basiert, normalisiert Einheiten und trennt gültige von ungültigen Datensätzen.

Aktuelle Fähigkeiten

Ingestion - Ein oder mehrere OpenAQ-Standorte - Einmaliger Lauf oder kontinuierliches Polling - Cache für Sensormetadaten	Zuverlässigkeit - Persistente Duplikatunterdrückung - Kafka-Zustellprüfung - Spark-Checkpoints und Kafka-Offsets
Datenqualität - Kanonischer Messvertrag - Normalisierte Feinstaub-Einheiten - Quarantine mit Fehlergrund	Entwicklungsbasis - Lokaler Kafka-Broker mit Docker Compose - Automatische Java-Erkennung für Spark - Fokussierte Tests und Ruff-Linting

Technischer Bestand

Der verbleibende Code ist bewusst klein und auf klar getrennte Verantwortlichkeiten zugeschnitten.

Modul	Verantwortung
openaq_client.py	HTTP-Zugriff, Endpunkte und API-Key-Handling
openaq_kafka_producer.py	Polling, Metadatenanreicherung und Deduplication
kafka_publisher.py	Serialisierung, Sensor-Key und Zustellprüfung
measurement_model.py	Schema, Validierung, Quarantine und Einheiten
measurement_kafka_stream.py	Kafka-Quelle, Spark-Orchestrierung und Parquet-Sinks
kafka_measurement_consumer.py	Betriebsdiagnostik ohne Offset-Commit
spark_runtime.py	Robuste lokale Java-Erkennung

Laufzeitpfade

Element	Aktueller Wert
Kafka Topic	environment.measurements.canonical
Gültige Daten	data/lake/canonical_measurements
Quarantine	data/lake/quarantine_measurements
Checkpoints	data/checkpoints/
Producer State	data/state/openaq_kafka_producer.json

Noch offen

- main und origin/main enthalten den Phase-0-Stand noch nicht.
- Eine CI-Pipeline auf GitHub ist noch nicht eingerichtet.
- Die Datenbasis umfasst bisher einen Standort und jeweils die neuesten Werte.
- Parquet ist ein Übergangziel; Apache Iceberg ist als Lakehouse-Schicht vorgesehen.

Phase 0 liefert einen stabilen technischen Kern. Phase 1 macht daraus ein kontinuierliches, fachlich nutzbares Datenprodukt.