

Projektziel

Eine belastbare Environmental Streaming Data Platform, die reale Umweltdaten kontinuierlich verarbeitet und daraus nachvollziehbare, aktuelle Informationen für Analyse und Warnung erzeugt.

Reale Quellen -> robuste Events -> verlässliche Datenprodukte -> sichtbarer Nutzen

Fachliches Zielbild

Das primäre Datenprodukt ist ein Live Air Quality Monitor für mehrere Städte und Messstationen. Er zeigt aktuelle Belastung, zeitliche Entwicklung, Datenfrische und auffällige Veränderungen.

Beobachten	Verstehen	Reagieren
- Aktuelle Schadstoffwerte je Standort - Zeitreihen und gleitende Mittelwerte - Datenfrische und Stationsstatus	- Vergleich von Städten und Zeiträumen - Einfluss von Wetter und Tageszeit - Unterscheidung von Ereignis und Sensorfehler	- Grenzwert- und Anomalie-Alerts - Nachvollziehbare Quarantine-Fälle - Replay und historische Neubewertung

Zielarchitektur




Spark bleibt die zentrale Verarbeitungsschicht für Validierung, Event-Time-Aggregationen und Lakehouse-Schreibvorgänge. Flink wird erst ergänzt, wenn ein klarer Low-Latency-Alerting-Use-Case einen zweiten Streaming-Runner fachlich rechtfertigt.

Portfolio-Signal

- Streaming Engineering mit Kafka, Spark, Checkpoints und Event Time
- Data Quality, Quarantine, Idempotenz und Replay-Fähigkeit
- Lakehouse-Modellierung mit Iceberg und reproduzierbaren Tabellen
- Observability, Infrastructure as Code und Cloud Deployment
- Ein fachlich sichtbares Produkt statt einer Sammlung isolierter Technik-Demos

Roadmap zum Zielbild

Die nächsten Phasen liefern jeweils ein eigenständig sichtbares Ergebnis.



Phase 1 - Reale Datenbasis

- Kuratierten Satz realer Standorte festlegen und konfigurieren.
- OpenAQ dauerhaft pollen und Fehler mit Retry/Backoff behandeln.
- Datenfrische, Event-Anzahl und Abdeckung sichtbar machen.

Phase 2 - Streaming Analytics und Lakehouse

- Event-Time-Fenster, Watermarks und verspätete Events umsetzen.
- Parquet-Sinks durch Apache-Iceberg-Tabellen ersetzen.
- Replay, Backfill und Tabellenwartung dokumentieren und testen.

Phase 3 - Fachliches Datenprodukt

- Wetterdaten anbinden und räumlich/zeitlich verknüpfen.
- Städtevergleich, Zeitreihen und Anomalien bereitstellen.
- Gezielte Alerts für Belastung und fehlende Daten erzeugen.

Phase 4 - Betrieb und Cloud

- Metriken, Logs, Kafka-Lag und Datenfrische überwachen.
- Infrastruktur mit Terraform aufbauen und reproduzierbar deployen.
- CI/CD, Security Checks und dokumentierte Betriebsabläufe ergänzen.

Erfolgskriterien

Dimension	Nachweis
Fachlich	Mehrere reale Standorte, verständliche Trends und Alerts
Technisch	Restart-fähige, idempotente und beobachtbare Datenstrecke
Datenqualität	Explizite Regeln, Quarantine und nachvollziehbare Fehler
Betrieb	Automatisierte Checks, Deployment und Monitoring
Portfolio	Klare Architekturentscheidungen und reproduzierbare Demo